






# Inferència probabilística en el temps



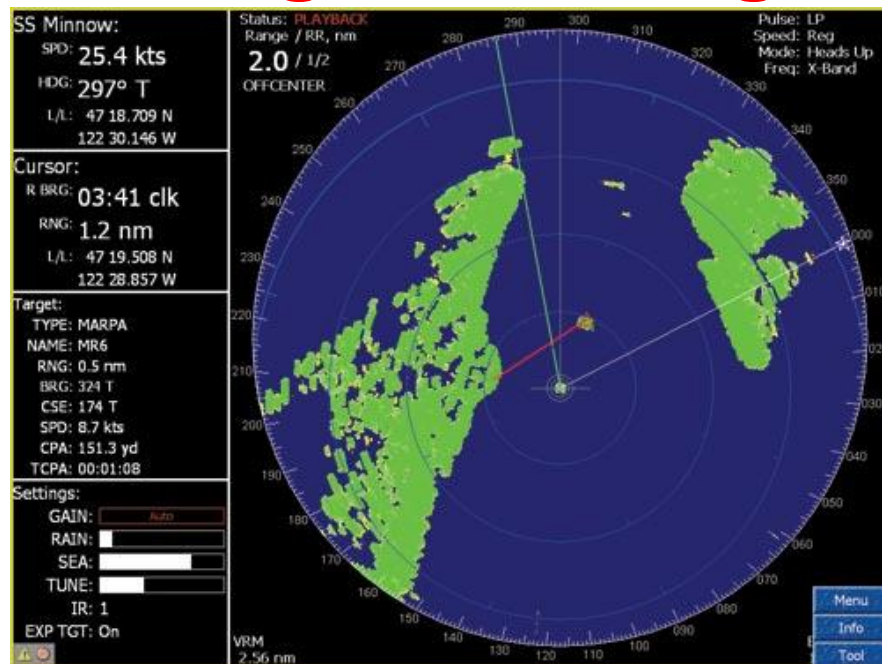
# Coneixement, Raonament i Incertesa.

# Reconeixement de la parla





- Donada una ona d'àudio, volem extreure i reconèixer paraules de forma robusta
- Els models estadístics es poden usar per a
  - Donar més robustesa al soroll
  - Adaptar-se a accents diferents
  - Aprendre del entrenament



# Target Tracking



*Següiment de múltiples objectius  
basat en radar*




*Seguiment visual d'objectes articulats  
(L. Sigal et. al., 2006)*

- Estimar el moviment de objectes en 3D a partir de mesures indirectes i potencialment sorolloses

# Navegació de Robots: **SLAM**

*Simultaneous Localization and Mapping*




*CAD  
Map*

(S. Thrun,  
San Jose Tech Museum)

*Mapa Estimada*



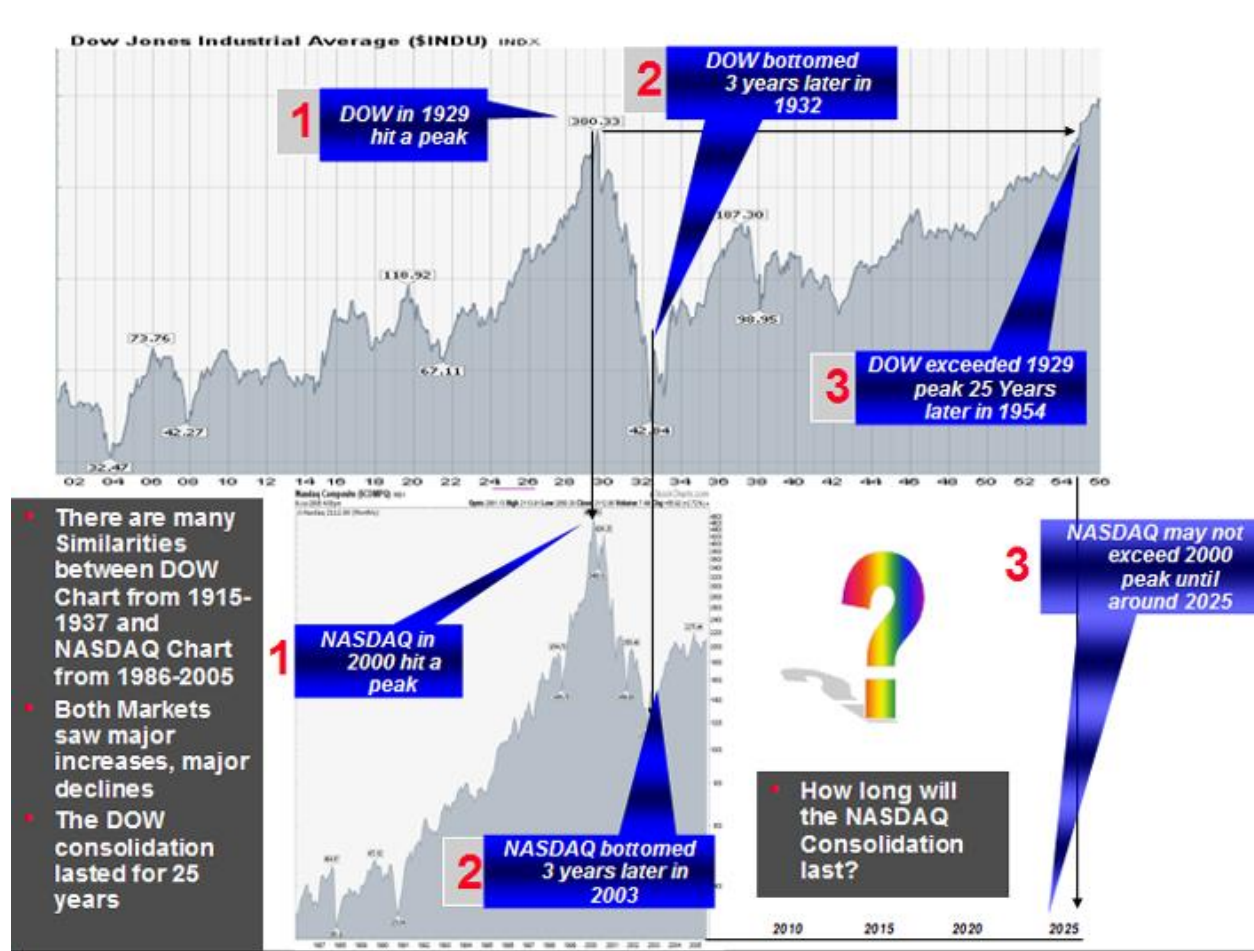
*Landmark  
SLAM  
(E. Nebot,  
Victoria Park)*



- Mentre el robot es mou, estimem la posició i la geometria del món




# Previsió financera



- Prediu el comportament futur del mercat a partir de dades històriques, notícies, opinions d'experts, ...

# Anàlisi de seqüències biològiques



(E. Birney, 2001)

- Els models temporals es poden adaptar a formes més genèriques d'estructures seqüencials, com les que apareixen en seqüències d'ADN

# Inferència en el temps

- Hidden Markov Models
- Filtre de Kalman
- Filtres de partícules
- Xarxes Bayesianes Dinàmiques (DBN)
- ...

# Processos seqüencials

- Considerem un sistema que pot prendre un dels  $N$  *estats* o *categories* discrets

$$x_t \in \{1, 2, \dots, N\} \rightarrow \text{estat al instant } t$$

- Estem interessats en sistemes *estocàstics*, en els que l'evolució del estat segueix una distribució probabilística
- Qualsevol joint distribution es pot factoritzar en una sèrie de distribucions condicionals (CPD) :

$$p(x_0, x_1, \dots, x_T) = p(x_0) \prod_{t=1}^T p(x_t \mid x_0, \dots, x_{t-1})$$



# Processos de Markov

- Per a un procés de *Markov*, el següent estat depèn només del estat actual:

$$p(x_{t+1} \mid x_0, \dots, x_t) = p(x_{t+1} \mid x_t)$$



- Al mateix temps, implica que

$$\begin{aligned} & p(x_0, \dots, x_{t-1}, x_{t+1}, \dots, x_T \mid x_t) \\ &= p(x_0, \dots, x_{t-1} \mid x_t) p(x_{t+1}, \dots, x_T \mid x_t) \end{aligned}$$

*“Condicionat en el present,  
el passat i el futur són independents”*

# Cadenes de Markov: Model gràfic


$$p(x_0, x_1, \dots, x_T) = p(x_0) \prod_{t=1}^T p(x_t | x_{t-1})$$



*nodes*



Valors d'estat en un  
temps determinat



*arestes*



Propietats de  
Markov

# Matrius de transició d'estat

- Una cadena de Markov *estacionaria* amb  $N$  estats es descriu amb una **matriu de transició** de :

$$Q = \begin{bmatrix} q_{11} & q_{12} & q_{13} \\ q_{21} & q_{22} & q_{23} \\ q_{31} & q_{32} & q_{33} \end{bmatrix}$$

$$q_{ij} \triangleq p(x_{t+1} = i \mid x_t = j)$$


- Restriccions en matrius de transició vàlides:

$$q_{ij} \geq 0 \quad \sum_{i=1}^N q_{ij} = 1 \quad \text{for all } j$$

# Diagrama de transició d'estats

$$q_{ij} \triangleq p(x_{t+1} = i \mid x_t = j)$$



$$Q = \begin{bmatrix} 0.5 & 0.1 & 0.0 \\ 0.3 & 0.0 & 0.4 \\ 0.2 & 0.9 & 0.6 \end{bmatrix}$$



- Pensem en una partícula que segueix una fletxa a l'atzar en cada instant de temps discret.
- Principalment útil quan N és petit i Q *sparse*

# Cadenes de Markov: Model gràfic


$$p(x_0, x_1, \dots, x_T) = p(x_0) \prod_{t=1}^T p(x_t | x_{t-1})$$



*nodes*



Valors d'estat en un  
temps determinat




*arestes*



Propietats de  
Markov

# Cadenes d'ordre superior


$$p(x_0, x_1, \dots, x_T) = p(x_0) \prod_{t=1}^T p(x_t \mid x_{t-1}, x_{t-2})$$



- Cada nou estat depèn d'una **finestra** de longitud fixa dels valors d'estat precedents
- Podem representar-ho com un model de primer ordre via **augmentats d'estats**:

$$\bar{x}_t \triangleq \{x_t, x_{t-1}\} \quad p(\bar{x}) = p(\bar{x}_1) \prod_{t=2}^T p(\bar{x}_t \mid \bar{x}_{t-1})$$


( $N^2$  estats augmentats)





# Procesos d'estat continuus

- En moltes aplicacions, és més natural definir els estats en algun estat continu:





- Exemples:* preu d'accions, posició d'avions, ...

# Example

$P_0$	
T	0.5
F	0.5

$P_{t-1}$	$P(P_t P_{t-1})$
T	0.7
F	0.3



$$Q = \begin{bmatrix} 0,7 & 0,3 \\ 0,3 & 0,7 \end{bmatrix}$$


# Hidden Markov Models

- Si tenim un model que satisfà les assumpcions dels processos de Markov

*“Condicionat en el present,  
el passat i el futur són independents”*


però i si no el podem observar ????

- Això motiva els *hidden Markov models* (**HMM**):



$$p(x_0, x_1, \dots, x_T) = p(x_0) \prod_{t=1}^T p(x_t | x_{t-1}) p(y_t | x_t)$$

# Estats ocults (hidden states)




- Donat  $x_t$ , les observacions prèvies no proporcionen informació addicional sobre el futur:

$$p(y_t, y_{t+1}, \dots \mid x_t, y_{t-1}, y_{t-2}, \dots) = p(y_t, y_{t+1}, \dots \mid x_t)$$

- Les transformacions de procés sota el que pren la dinàmica prenen forma de primer ordre.


# D'on venen els estats?



- Anàlisi d'un fenomen físic:
  - Model dinàmics d'un avió o robot
  - Models geofísics d'evolució climàtica
- Obtinguts de dades d'entrenament:
  - Exemples gravats de català parlat
  - Comportament històric dels preus de les accions

[http://en.wikipedia.org/wiki/Hidden\\_Markov\\_model](http://en.wikipedia.org/wiki/Hidden_Markov_model)

# HMMs amb estats discrets



- Associar cada un dels  $N$  estats ocults amb una distribució d'observació diferent:

$$p(y_t \mid x_t = 1) \quad p(y_t \mid x_t = 2) \quad \dots$$

- Les densitats d'observació reflexen el coneixement del domini



# HMMs Discrets: Observacions

## Observacions Discretes



$$y_t \in \{1, 2, \dots, M\}$$

$$p(y_t \mid x_t = 1) = \begin{bmatrix} 0.3 \\ 0.1 \\ 0.5 \\ 0.1 \end{bmatrix}$$


$$p(y_t \mid x_t = 2) = \begin{bmatrix} 0.2 \\ 0.2 \\ 0.1 \\ 0.5 \end{bmatrix}$$

## Observacions Continues

$$y_t \in \mathbb{R}^k$$



# Especificació d'una HMM



- Model d'observació:  $\pi$

$$P(y_i | x_i) \quad m \times n$$

Quan tenim l'observació només usem una columna  $\pi_i$

- Model de transició:  $Q$

$$P(x_i | x_{i-1}) \quad n \times n$$



- Distribució d'estat inicial:

$$P(x_0) \quad n \times 1$$

$n$ : número de possibles valors (estats) dels nodes ocults

$m$ : número de possibles valors de les observacions

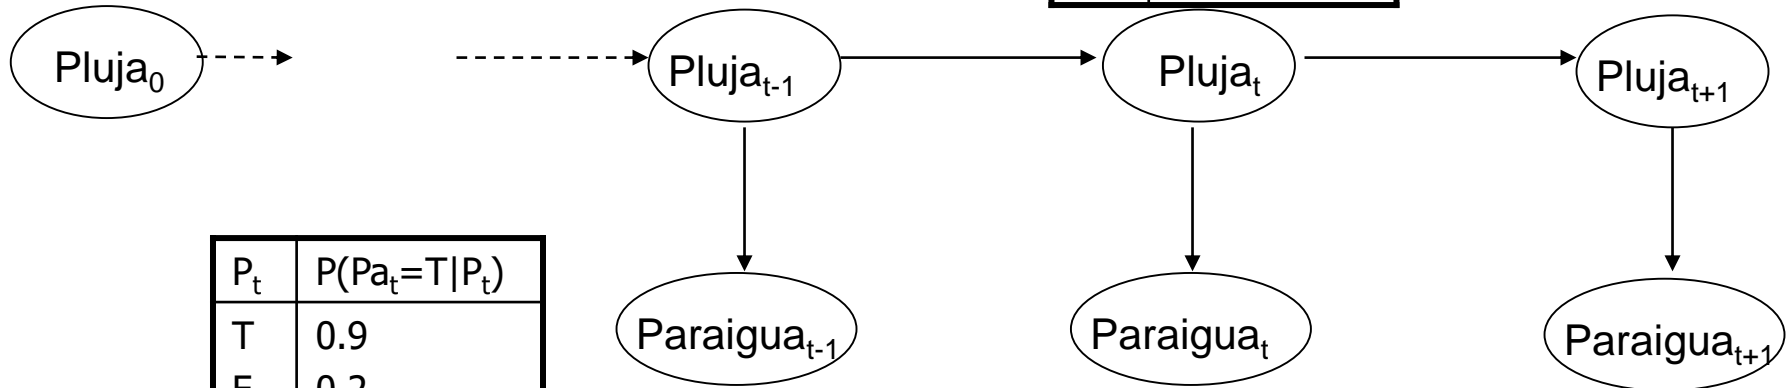
# Exemple



$P_0$	
T	0.5
F	0.5



$P_{t-1}$	$P(P_t=T P_{t-1})$
T	0.7
F	0.3

$P_t$	$P(Pa_t=T P_t)$
T	0.9
F	0.2




Quina és la probabilitat de que plogui el dia 2, sabent que el dia 1 i el dia 2 hem vist el paraigua?

# Exemple




$P_0$	
T	0.5
F	0.5






$P_{t-1}$	$P(P_t P_{t-1})$
T	0.7
F	0.8

Q	Plou	NoPlou
Plou	0.7	0.8
No Plou	0.3	0.2




$P_t$	$P(Pa_t P_t)$
T	0.9
F	0.2



$\pi$	plou	noplou
paraigua	0.9	0.2
noparaigua	0.1	0.8

plou, no plou, paraigua, no paraigua  
NO són variables, són estats

# Example



$x_i$

$y_i$

$P_0$	
T	0.5
F	0.5

$Q$	Plou	NoPlou
Plou	0.7	0.8
No Plou	0.3	0.2

$\pi$	plou	noplou
paraigua	0.9	0.2
noparaigua	0.1	0.8

# Tasques d'inferència

- **Filtratge (Filtering o monitoring):**  $P(X_t|y_1, \dots, y_t)$

calcular la certesa sobre l'estat actual, donades totes les evidències fins al moment

- **Predicció:**  $P(X_{t+k}|y_1, \dots, y_t)$

calcular la probabilitat d'un estat futur

- **Suavitzat (Smoothing):**  $P(X_k|y_1, \dots, y_t) \quad k < t$

calcular la probabilitat d'un estat pasat (retrospectiva)

- **Explicació més plausible (Decoding):**  $\arg \max_{x_1, \dots, x_t} P(x_1, \dots, x_t|y_1, \dots, y_t)$

donada una seqüència d'observacions, trobar la seqüència d'estats més probable que hagi pogut generar les observacions.



# Exemples

- **Filtratge:** Quina és la probabilitat que plogui avui, donada totes les observacions de paraigües fins avui?
- **Predicció:** Quina és la probabilitat que plogui passat demà, donades totes les observacions de paraigua fins avui?
- **Smoothing:** Quina és la probabilitat que ahir plugués, donades totes les observacions de paraigua fins avui?
- **Explicació més plausible:** si el paraigua ha aparegut els primers tres dies i no el quart, quin és la seqüència de temps més plausible per a produir les observacions de paraigua?

# Filtratge i Suavització (filtering & smoothing)

- Per anàlisi de dades online, busquem l'estimació d'estat **filtrada** donades les observacions anteriors:

$$p(x_t \mid y_1, y_2, \dots, y_t) \quad t = 1, 2, \dots$$

- En altres casos, volem trobar estimacions **suavitzades** donades les observacions prèvies i posteriors:

$$p(x_t \mid y_1, y_2, \dots, y_T) \quad t = 1, 2, \dots, T$$

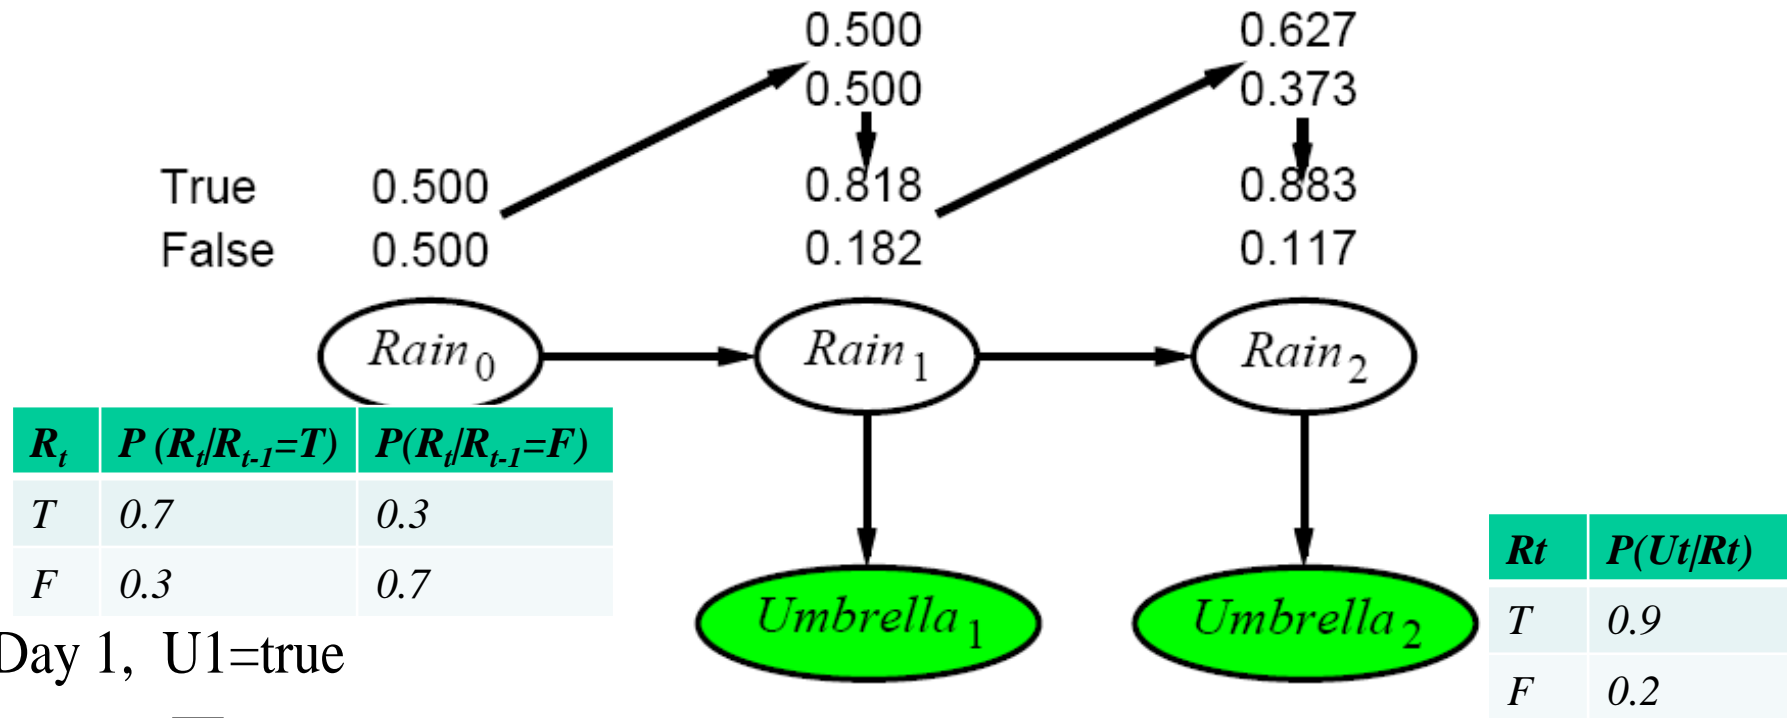
- Depenent com variem  $T$ :

*fixed-lag smoothing* & *predicció*:

$$p(x_t \mid y_1, \dots, y_{t+\delta})$$

$$p(x_t \mid y_1, \dots, y_{t-\delta})$$

# Exemple Filtering



Day 1,  $U_1 = \text{true}$

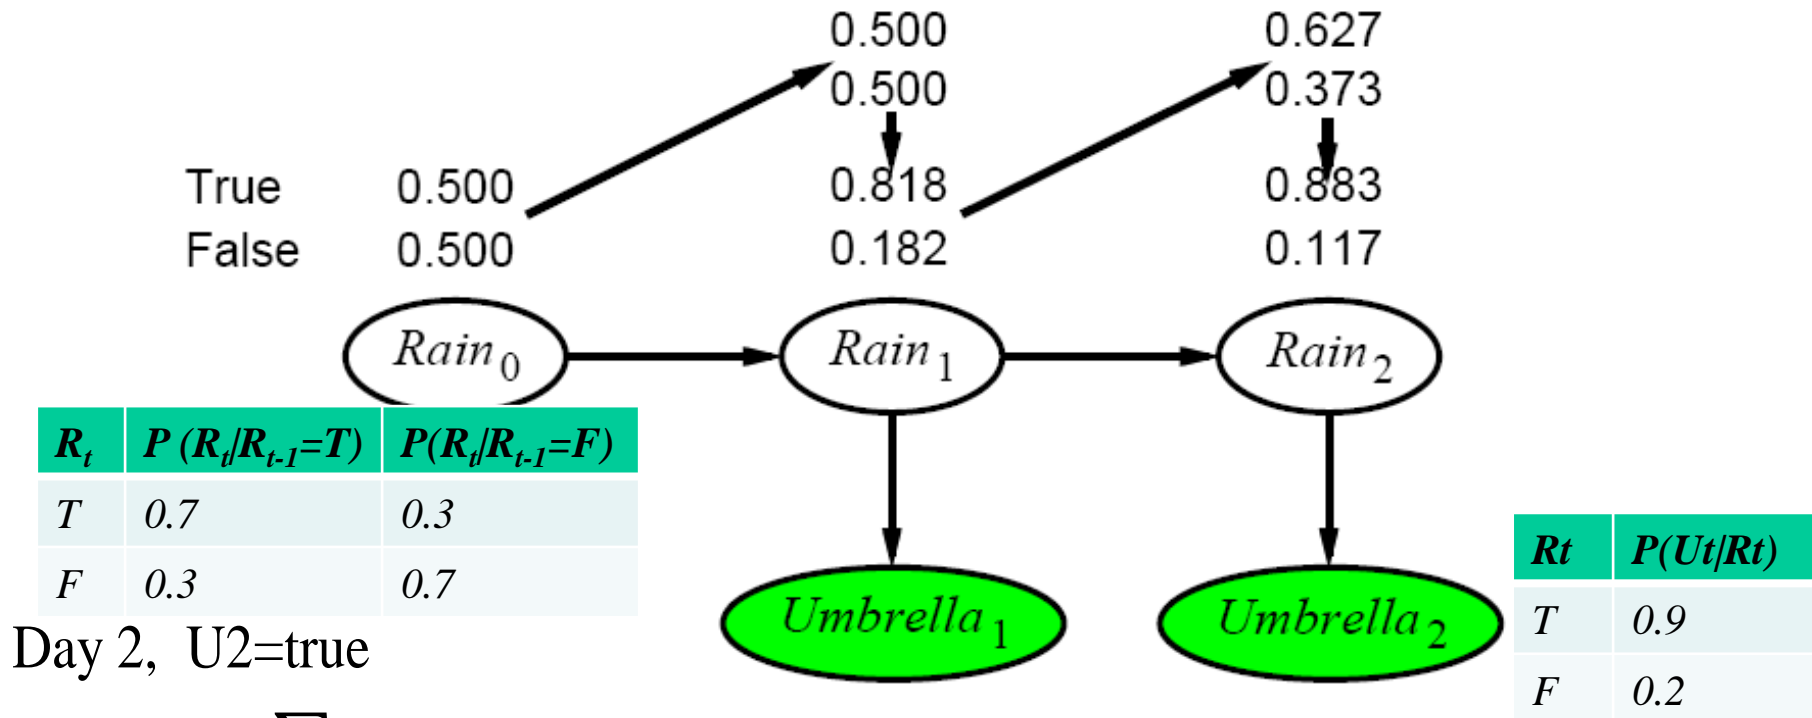
$$p(R_1) = \sum_{r_0} p(R_1 | r_0) p(r_0)$$

$$= \langle 0.7, 0.3 \rangle \times 0.5 + \langle 0.3, 0.7 \rangle \times 0.5 = \langle 0.5, 0.5 \rangle$$

$$p(R_1 | u_1) = \alpha p(u_1 | R_1) p(R_1) = \alpha \langle 0.9, 0.2 \rangle \times \langle 0.5, 0.5 \rangle$$

$$= \alpha \langle 0.45, 0.1 \rangle = \langle 0.818, 0.182 \rangle$$

# Example Filtering



Day 2,  $U_2 = \text{true}$


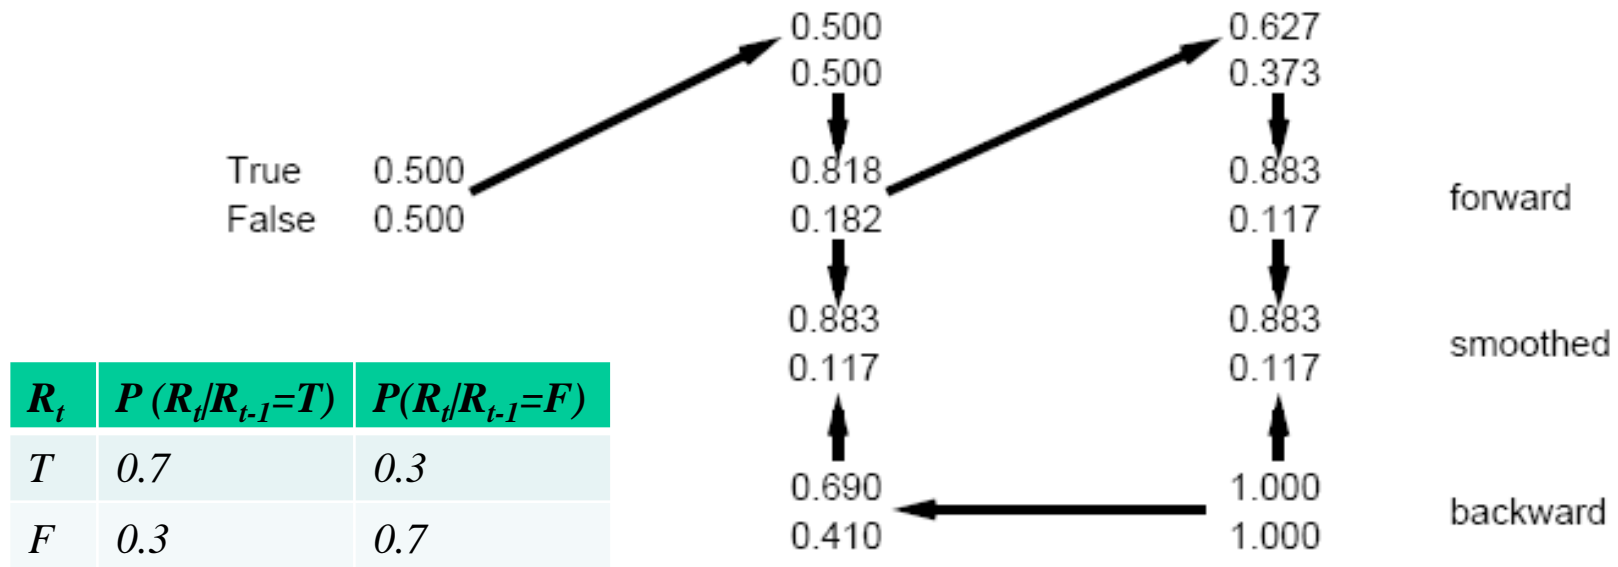
$$p(R_2 | u_1) = \sum_{r_1} p(R_2 | r_1) p(r_1 | u_1)$$

$$= \langle 0.7, 0.3 \rangle \times 0.818 + \langle 0.3, 0.7 \rangle \times 0.182 = \langle 0.627, 0.373 \rangle$$

$$p(R_2 | u_1, u_2) = \alpha p(u_2 | R_2) p(R_2 | u_1) = \alpha \langle 0.9, 0.2 \rangle \times \langle 0.627, 0.373 \rangle$$

$$= \alpha \langle 0.565, 0.075 \rangle = \langle 0.883, 0.117 \rangle$$


# Exemple Smoothing



$R_t$	$P(U_t/R_t)$
$T$	0.9
$F$	0.2

$$\begin{aligned}
 p(u_2 | R_1) &= \sum_{r_2} p(u_2 | r_2) p(r_2 | R_1) = \\
 &= 0.9 \times 1 \times \langle 0.7, 0.3 \rangle + 0.2 \times 1 \times \langle 0.3, 0.7 \rangle = \langle 0.69, 0.41 \rangle
 \end{aligned}$$

# Estadística de les cadenes de Markov




- Per definició de probabilitats condicionals,

$$\alpha_1(i) = \sum_{j=1}^N q_{ij} \alpha_0(j) \quad \left\{ \begin{array}{l} \alpha_1 = Q \alpha_0 \\ \alpha_t = Q^t \alpha_0 \\ \alpha_\infty = ??? \end{array} \right.$$




# Estadística de les cadenes de Markov



$$\alpha_t \triangleq \begin{bmatrix} p(x_t = 1) \\ p(x_t = 2) \\ p(x_t = 3) \end{bmatrix}$$

$$Q = \begin{bmatrix} q_{11} & q_{12} & q_{13} \\ q_{21} & q_{22} & q_{23} \\ q_{31} & q_{32} & q_{33} \end{bmatrix}$$

$$q_{ij} \triangleq p(x_{t+1} = i \mid x_t = j)$$





- Per definició de probabilitats condicionals,

$$P(x_1 = i) = \sum_j^n P(x_1 = i, x_0 = j) = \sum_j^n \underbrace{P(x_1 = i | x_0 = j)}_{q_{ij}} \underbrace{P(x_0 = j)}_{\alpha_0(j)} = Q_i \cdot \alpha_0 = \alpha_1(i)$$

$$\alpha_1 = Q \alpha_0$$

# Estadística de les cadenes de Markov



$$\alpha_t \triangleq \begin{bmatrix} p(x_t = 1) \\ p(x_t = 2) \\ p(x_t = 3) \end{bmatrix}$$

$$Q = \begin{bmatrix} q_{11} & q_{12} & q_{13} \\ q_{21} & q_{22} & q_{23} \\ q_{31} & q_{32} & q_{33} \end{bmatrix}$$


$$q_{ij} \triangleq p(x_{t+1} = i \mid x_t = j)$$

- Per definició de probabilitats condicionals,

$$\begin{aligned} P(x_2 = i) &= \sum_k^n \sum_j^n P(x_2 = i, x_1 = k, x_0 = j) = \sum_k^n \sum_j^n P(x_2 = i | x_1 = k) P(x_1 = k | x_0 = j) P(x_0 = j) \\ &= \sum_k^n P(x_2 = i | x_1 = k) \alpha_1(k) = Q_{i \cdot} \times \alpha_1 = \alpha_1(i) \end{aligned}$$

$$\alpha_2 = Q \alpha_1 = Q Q \alpha_0 = Q^2 \alpha_0$$

# HMMs discrets: Filtering



$$\alpha_t(x_t) \triangleq p(x_t \mid y_1, \dots, y_t)$$

$$= \frac{1}{Z_t} p(y_t \mid x_t) \sum_{x_{t-1}} p(x_t \mid x_{t-1}) \alpha_{t-1}(x_{t-1})$$

Constant de  
Normalització

Predicció:


$$p(x_t \mid y_1, \dots, y_{t-1})$$

actualització:

$$p(x_t \mid y_1, \dots, y_t)$$

Incorpora  $T$  observacions en  $\mathcal{O}(TN^2)$  operacions

# HMMs discrets: Smoothing



$$p(x_t | y) \propto \underbrace{p(x_t | y_1, \dots, y_t)}_{\alpha_t(x_t)} \underbrace{p(y_{t+1}, \dots, y_T | x_t)}_{\beta_t(x_t)}$$

- L'algorisme *forward-backward* actualitza a partir d'una recursió en temps invers:

$$\beta_t(x_t) = \frac{1}{Z_t} \sum_{x_{t+1}} p(x_{t+1} | x_t) p(y_{t+1} | x_{t+1}) \beta_{t+1}(x_{t+1})$$

## resum

$$p(x_t \mid y) \propto \underbrace{p(x_t \mid y_1, \dots, y_t)}_{\alpha_t(x_t)} \underbrace{p(y_{t+1}, \dots, y_T \mid x_t)}_{\beta_t(x_t)}$$

$$\alpha_t(x_t) \triangleq \frac{1}{Z_t} p(y_t \mid x_t) \sum_{x_{t-1}} p(x_t \mid x_{t-1}) \alpha_{t-1}(x_{t-1})$$

$$\beta_t(x_t) = \frac{1}{Z_t} \sum_{x_{t+1}} p(x_{t+1} \mid x_t) p(y_{t+1} \mid x_{t+1}) \beta_{t+1}(x_{t+1})$$

- Filtering:  $p(x_t \mid y_1, \dots, y_t) = \alpha_t(x_t)$
- Smoothing:  $p(x_t \mid y) = \alpha_t(x_t) \beta_t(x_t)$

# càlcul

$$p(x_t \mid y) \propto \underbrace{p(x_t \mid y_1, \dots, y_t)}_{\alpha_t(x_t)} \underbrace{p(y_{t+1}, \dots, y_T \mid x_t)}_{\beta_t(x_t)}$$

$$\alpha_t(x_t) \triangleq \frac{1}{Z_t} p(y_t \mid x_t) \sum_{x_{t-1}} p(x_t \mid x_{t-1}) \alpha_{t-1}(x_{t-1})$$

- Filtering:

$$p(x_t \mid y_1, \dots, y_t) = \alpha_t(x_t)$$

$$\alpha_t(x_t) = \text{diag}(\pi_{y_t}) \cdot Q^T \cdot \alpha_{t-1}(x_{t-1})$$

# càlcul

$$p(x_t \mid y) \propto \underbrace{p(x_t \mid y_1, \dots, y_t)}_{\alpha_t(x_t)} \underbrace{p(y_{t+1}, \dots, y_T \mid x_t)}_{\beta_t(x_t)}$$

$$\alpha_t(x_t) \triangleq \frac{1}{Z_t} p(y_t \mid x_t) \sum_{x_{t-1}} p(x_t \mid x_{t-1}) \alpha_{t-1}(x_{t-1})$$

$$\beta_t(x_t) = \frac{1}{Z_t} \sum_{x_{t+1}} p(x_{t+1} \mid x_t) p(y_{t+1} \mid x_{t+1}) \beta_{t+1}(x_{t+1})$$

- smoothing:

$$p(x_t \mid y_1, \dots, y_T) = \alpha_t(x_t) \cdot \beta_t(x_t)$$

$$\beta_t(x_t) = Q \cdot \text{diag}(\pi_{y_{t+1}}) \cdot \beta_{t+1}(x_{t+1})$$

# HMMs discrets: Explicació més plausible

## Algorisme de Viterbi

$$\hat{x} = \arg \max_x p(x_0, x_1, \dots, x_T \mid y_1, \dots, y_T)$$

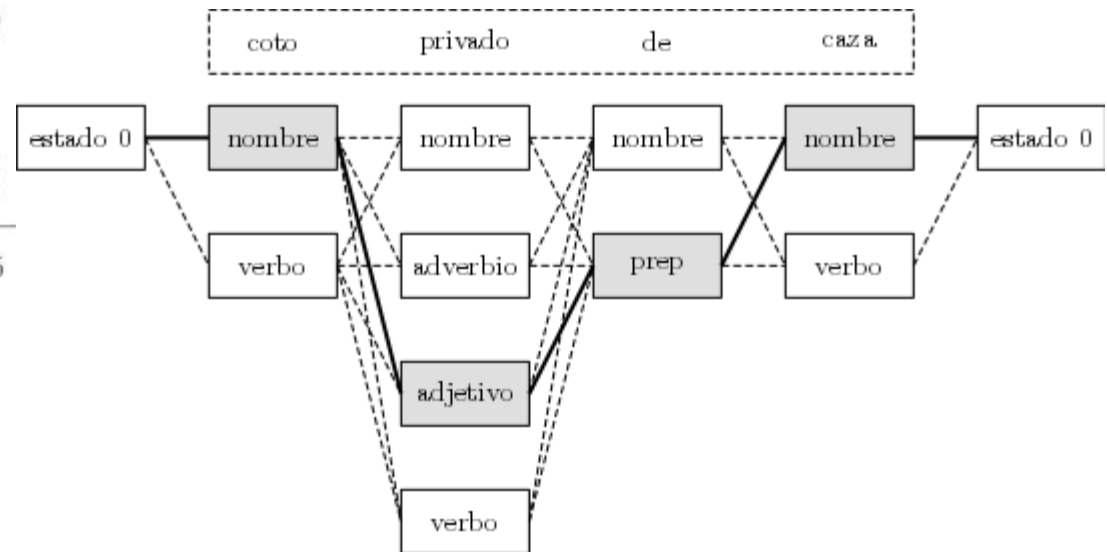

- Usa programació dinàmica per trobar recursivament la probabilitat de la seqüència d'estats més plausible que acaba amb cada un dels  $x_t \in \{1, \dots, N\}$

$$\begin{aligned} \gamma_t(x_t) &\triangleq \max_{x_1, \dots, x_{t-1}} p(x_1, \dots, x_{t-1}, x_t \mid y_1, \dots, y_t) \\ &\propto p(y_t \mid x_t) \cdot \left[ \max_{x_{t-1}} p(x_t \mid x_{t-1}) \gamma_{t-1}(x_{t-1}) \right] \end{aligned}$$

$\gamma_t(i)$  És la 'millor' probabilitat d'haver d'estar en l'estat ' $i$ ' havent observat les  $t$  primeres entrades

- Un procediment de backtracking 'reverse-time' tria la seqüència d'estats màximitzadora






# Exemple Viterbi

$\pi$	plou	noplu
paraigua	0.9	0.2
noparaigua	0.1	0.8

$Q$	Plou	NoPlou
Plou	0.7	0.8
No Plou	0.3	0.2



$$\gamma_t(x_t) \propto p(y_t | x_t) \cdot \left[ \max_{x_{t-1}} p(x_t | x_{t-1}) \gamma_{t-1}(x_{t-1}) \right]$$

# HMMs discrets: Learning

- Suposem que tenim la sequència dels estats latents durant el training
- La *maximum likelihood* és

$$(\hat{Q}, \hat{\theta}) = \arg \max_{Q, \theta} p(x \mid Q)p(y \mid x, \theta)$$

$$Q = [q_{ij}] = [p(x_{t+1} = i \mid x_t = j)]$$

$$\theta = \{\theta_i\}_{i=1}^N \quad (\text{distribucions d'observació})$$

- Per simplicitat, assumim que les observacions són gaussianes amb variança i mitjana conegudes  $\theta_i$

# HMMs discrets: Learning

- L'estimador ML de la matriu de transició ve donada per 'comptadors normalitzats' :

$$n(i, j) \triangleq \begin{cases} \text{Número de vegades} \\ \text{Observat anteriorment} \end{cases} \begin{matrix} x_t = j \\ x_{t+1} = i \end{matrix}$$

$$\hat{q}_{ij} = \frac{n(i, j)}{\sum_k n(k, j)}$$

- Donat  $x$ , independentment estimar la distribució de sortida per a cada estat:

$$\hat{\theta}_i = \frac{1}{|\tau_i|} \sum_{t \in \tau_i} y_t$$

$$\tau_i \triangleq \{t \mid x_t = i\}$$

# HMMs discrets: algorisme EM

- A la pràctica normalment no coneixem els estats ocults en les seqüències d'entrenament
- L'algorisme EM iterativament maximitza un 'lower bound' en la likelihood de les dades:

**E-Step:** Usem els parametres actuals per estimar l'estat

$$\hat{p}^{(s)}(x) = p(x \mid y, \hat{Q}^{(s-1)}, \hat{\theta}^{(s-1)})$$

**M-Step:** Usem estimadors d'estat 'soft' per actualitzar paràmetres

$$(\hat{Q}^{(s)}, \hat{\theta}^{(s)}) = \arg \max_{Q, \theta} \sum_x \hat{p}^{(s)}(x) \log p(x \mid Q) p(y \mid x, \theta)$$

*Aplicat a HMMs, és equivalent a l'algorisme Baum-Welch*

# HMMs discrets: algorisme EM


- Donada l'estructura de Markov, l'actualització de paràmetres EM usa els estadístics locals usant l'algorisme *forward-backward* (*E-step*)
- El pas de maximització (*M-step*) estima la distribució de les observacions via una mitjana 'pesada' (weighted average):

$$\hat{\theta}_i^{(s)} = \frac{\sum_t \hat{p}^{(s)}(x_t = i) y_t}{\sum_t \hat{p}^{(s)}(x_t = i)}$$

- La matriu de transició es calcula de la mateixa manera...



Podem trobar mínims locals, la inicialització és fonamental.

# Schematic Architecture for a (simplified) Speech Recognizer



# Markov Random Fields en Visió

Idea: pixels veïns són similars.

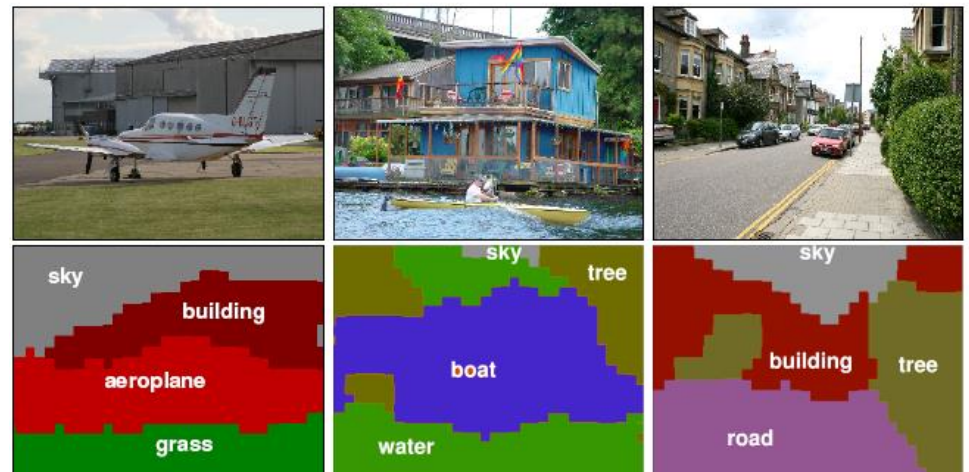


**fMRI Analysis** (Kim et. al. 2000)



**Image Denoising**

(Felzenszwalb & Huttenlocher 2004)



**Segmentation & Object Recognition**

(Verbeek & Triggs 2007)



